Université de Mayotte
Département de Mathématiques

Sujet : Modélisation spatio-temporelle de l'abondance des poulpes à Mayotte

Objectif 1 – Contexte scientifique et revue bibliographique

Réalisé par :
ATTOUMANI Ibrahim

Année Universitaire 2025 – 2026

Table des matières

1. Modèle hiérarchique **2**
1.1. Modèle d'abondance 2
1.2. La structure du modèle 3
1.3. La notion de surdispersion 4

1. Modèle hiérarchique

Un modèle hiérarchique est un modèle probabiliste dans lequel certains paramètres sont eux-mêmes considérés comme des variables aléatoires, dépendant d'hyperparamètres.

1.1. Modèle d'abondance

Dans le cas d'un modèle d'abondance, nous avons :

$$\begin{cases} n_{i,t} \mid N_i \sim \mathcal{B}(N_i, p_{it}) \\ N_i \sim \mathcal{P}(\lambda_i) \end{cases} \qquad (n_{i,t} \to N_i \to \lambda_i)$$

où :

- $n_{i,t}$ est le nombre d'individus observés au site i lors de la visite t ;
- N_i est le nombre réel d'individus présents dans le site i ;
- p_{it} est la probabilité de détection ;
- λ_i est le paramètre d'abondance moyenne du site i.

Pour plus de détails, voir la Figure~1.

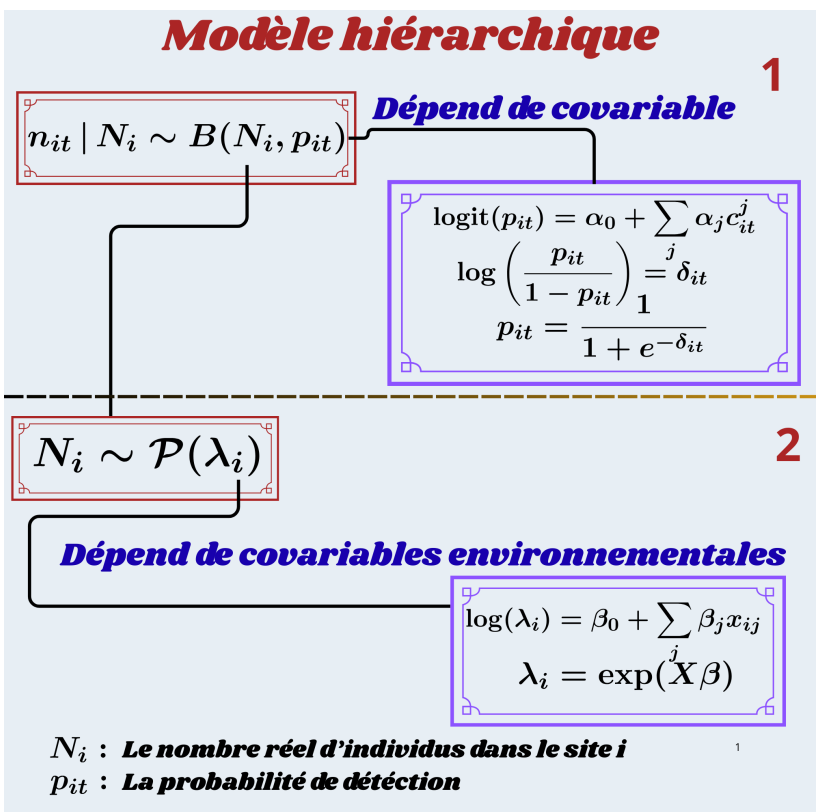

FIGURE 1 – Schéma du modèle d'abondance

1.2. La structure du modèle

Le vrai nombre d'individus par site est inconnu (**variables latentes**), on le note :

$$N = \begin{bmatrix} N_1 \\ N_2 \\ \vdots \\ N_R \end{bmatrix} \in \mathbb{R}^R$$

où R est le nombre de sites.

Pour tout, $i \in 1, \ldots, R$, $N_i \sim \mathcal{P}(\lambda_i)$ (ou $N_i \sim \mathcal{BN}$).

Pour chaque site i, le tableau X ci-dessous contient les covariables environnementales :

$$X = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ 1 & x_{2,1} & \cdots & x_{2,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{R,1} & \cdots & x_{R,p} \end{bmatrix} \in \mathbb{R}^{R \times (p+1)}$$

L'abondance varie selon le site. Si $N_i \sim \mathcal{P}(\lambda_i)$, on peut modéliser l'abondance via une régression log-linéaire :

$$\begin{aligned} & \log(\lambda_i) = \beta_0 + \sum_{j=1}^{p} \beta_j x_{ij} \\ \iff & \log(\lambda) = X\beta \\ \iff & \lambda = \exp(X\beta) \end{aligned}$$

avec

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix} \in \mathbb{R}^{p+1}$$

Les données observées lors de visites répétées :

$$Y = \begin{bmatrix} n_{1,1} & \cdots & n_{1,T} \\ n_{2,1} & \cdots & n_{2,T} \\ \vdots & \vdots & \ddots & \vdots \\ n_{R,1} & \cdots & n_{R,T} \end{bmatrix} \in \mathbb{R}^{R \times T}$$

où $i = site_i$ et $t = temps_t$ (visite répétée). Conditionnellement à N_i :

$$n_{it} \sim \mathcal{B}(N_i, p)$$

Or, la probabilité de détéction p peut dépendre également de covariables, telles que le moment de la journée, la saison ou l'observateur (humain).

Pour simplifier, on considère 4 covariables :

- c^1 = latitude
- c^2 = longitude
- c^3 = température
- c^4 = humidité

On note :

$$\Delta = \begin{bmatrix} 1 & c_{11}^1 & \cdots & c_{11}^q \\ \vdots & \vdots & \ddots & \vdots \\ 1 & c_{1T}^1 & \cdots & c_{1T}^q \\ 1 & c_{22}^1 & \cdots & c_{22}^q \\ \vdots & \vdots & \ddots & \vdots \\ 1 & c_{RT}^1 & \cdots & c_{RT}^q \end{bmatrix} \in \mathbb{R}^{RT \times (q+1)}$$

où chaque une ligne correspond à une observation site-temps.

La probabilité de détéction peut être modéliser par la fonction de lien logistique *(McCullag et Nelder 1989)* :

$$\begin{aligned} \text{logit}(p_{it}) &= \alpha_0 + \sum_{j=1}^{q} \alpha_j c_{it}^j = \delta_{it} \\ \iff \log\left(\frac{p_{it}}{1-p_{it}}\right) &= \delta_{it} \\ \iff \frac{p_{it}}{1-p_{it}} &= \mathrm{e}^{\delta_{it}} \\ \iff p_{it} &= \frac{\mathrm{e}^{\delta_{it}}}{1+\mathrm{e}^{\delta_{it}}} \\ \iff p_{it} &= \frac{1}{1+\mathrm{e}^{-\delta_{it}}} \end{aligned}$$

1.3. La notion de surdispersion

Soit $N_i \sim P_\theta$ une variable de moyenne $\mu = \mathbb{E}(N_i)$ et de variance $\text{Var}(N_i)$. On parle de surdispersion lorsque

$$\text{Var}(N_i) > \text{Var}P_\theta(N_i),$$

c'est-à-dire, lorsque la variance observée est supérieure à la variance attendu sous le modèle P_θ.

Dans un modèle de poisson, $N_i \sim \mathcal{P}(\lambda_i)$, il y a surdispertion lorsque $\mathrm{Var}(N_i) > \lambda_i$. Il est alors judicieux d'utiliser un modèle altérnatives comme la loi binomiale négative, qui permet de modéliser une variance plus élevée.