Université de Mayotte
Département de Mathématiques

Sujet : Modélisation spatio-temporelle de l'abondance des poulpes à Mayotte

Objectif 2 : Exploration et compréhension des données

Réalisé par :
ATTOUMANI Ibrahim

Année Universitaire 2025 – 2026

Table des matières

1. Nettoyage des données **2**
1.1. Importation des données 2
1.2. Gestion des valeurs manquantes 3

2. Analyses descriptives univariées **3**
2.1. Les premières graphiques : Histogrammes, Barplots et Boxplots 3
2.2. Distribution des NA et détection des outliers 9

3. Analyses descriptives bivariées **10**

4. Analyses descriptives multidimentionnelles **10**

5. Analyses descriptives pour les variables qualitatives **12**
5.1. La distribution des modalités 14
5.2. Relation d'indépendance 14
5.3. Analyse de corespondances multiples 14

6. Annexe **15**
6.1. Annexe A : Les fonctions codées 15
6.1.1. plt_hist_uni 15
6.1.2. plt_bar_uni 16
6.1.3. box_plt_uni 16
6.1.4. MAD 16
6.1.5. Z_rob 17
6.1.6. detect_outlier 17
6.2. Annexe B : Description des Variables quantitatives 18
6.3. Annexe C : Description des Variables qualitatives 19
6.4. Annexe D : Autres visualisatons 20

1. Nettoyage des données

Le nettoyage des données est la première étape de l'analyse des données. Cette étape est essentielle et permet d'améliorer la qualité des données avant la modélisation. Il consiste à détecter, corriger voire supprimer des données incorrectes, incohérentes ou dupliquées. Il existe plusieurs problèmes courants dans les données, notamment la gestion des valeurs manquantes, les erreurs de format, la détection des outliers (valeurs atypique ou aberrantes).

1.1. Importation des données

```
# importation des données
# Attention: il faut penser à changer le chemin vers les données si nécessaire

dt <- read.csv("data/Octopus_data.csv", header = TRUE, sep = ",")
```

Le jeu de données contient 372 observations et 77 variables. Il comprend différents types de variables :

- Quantitatives continues
- Catégorielles
- Temporelle (dates, heures)

On remarque que les variables temporelles sont codées en caractères. Nous allons donc les convertir au format approprié (date,heure,minute).

Il existe également des variables nominales (num.individus, num.pechejour, num.pratiquejour) qui sont codées sous forme numérique.

```
# variables nominales qui sont sous forme numerique
var_nom <- c("num.individus", "num.pechejour", "num.pratiquejour")

for (c in var_nom) {
  df[[c]] <- as.character(df[[c]])
}
```

Nous coderons ensuite d'autres variables dérivées, telles que la durée, latitude/longitude (séparation des points GPS).

```
# la duree sera en minute
df$duree <- df$heurefin - df$heuredebut

df$heurefinenq <- df$heuredebutenq + df$dureeenq
```

1.2. Gestion des valeurs manquantes

2. Analyses descriptives univariées

On sépare les données en trois tableaux :

- **df_quant** contiendra toutes les variables quantitatives ;
- **df_qual** contiendra toutes les variables qualitatives ;
- **df_temp** contiendra toutes les variables temporelles.

Dans un premier temps, on s'intéresse aux données quantitatives (df_quant).

Ce tableau comprend 23 variables, toutes quantitatives comme indiqué. On distingue deux types de variables quantitatives, discrète telle que nbhommespec et continue comme la taille.

2.1. Les premières graphiques : Histogrammes, Barplots et Boxplots

Nous allons écrire deux fonctions : l'une affichant l'histogramme de toutes les variables quantitatives continues données et qui rajoute sur le même graphe la densité de celles-ci. L'autre fonction affiche le boxplot d'une variable.

Nous décrirons en détail les paramètres de chaque fonction en Annexe. Ce choix me paraît judicieux pour alléger la rédaction (ne pas réécrire un code plusieurs fois) car nous avons plusieurs variables à analyser

On a également programmer une troisième fonction qui affiche un barplot pour les variables discrètes.

Le barplot affiche la fréquence du nombre d'individus récoltés. On constate que les valeurs 1, 2, 3, 4 et 9 apparaissent souvent, en revanche la valeur 5 est moins fréquente.

Comme on peut l'observer dans la Figure @ref(fig :figure1),le boxplot résume la distribution. On constate que la médiaane est autour de 3 individus. La majorité des observations sont entre 1 et 4 (intervalle interquartille). On observe également également une valeur atypique autour de 9 individus.

L'histogramme avec la courbe de densité (en rouge) de la Figure @ref(fig :figure2) montre la distribution des poids récoltés. La majorité des poids se situe entre $500g$ et $2000g$, le boxplot confirme cela d'après l'intervalle interquartille. On constate une médiane autour de 1250 et 1350. On aperçoit également plusieurs mode indiquant peut-être la présence de plusieurs sous-populations.

La Figure @ref(fig :figure3) affiche la distribution de la taille de l'individu (LM). La majorité des tailles sont compris entre $13cm$ et $18cm$, où la médiane est autour de $15cm$. On peut constater une légère asymétrie à droite, causée par deux valeurs élevées rares ($25cm$ et $27cm$), visible égalment sur le boxplot.

Sur la figure @ref(fig :figure4), la plupart des tailles sont autour de $60cm$ et $100cm$. Une médiane autour de $70cm$ avec quelques atypiques, elles reste malgré plausible.

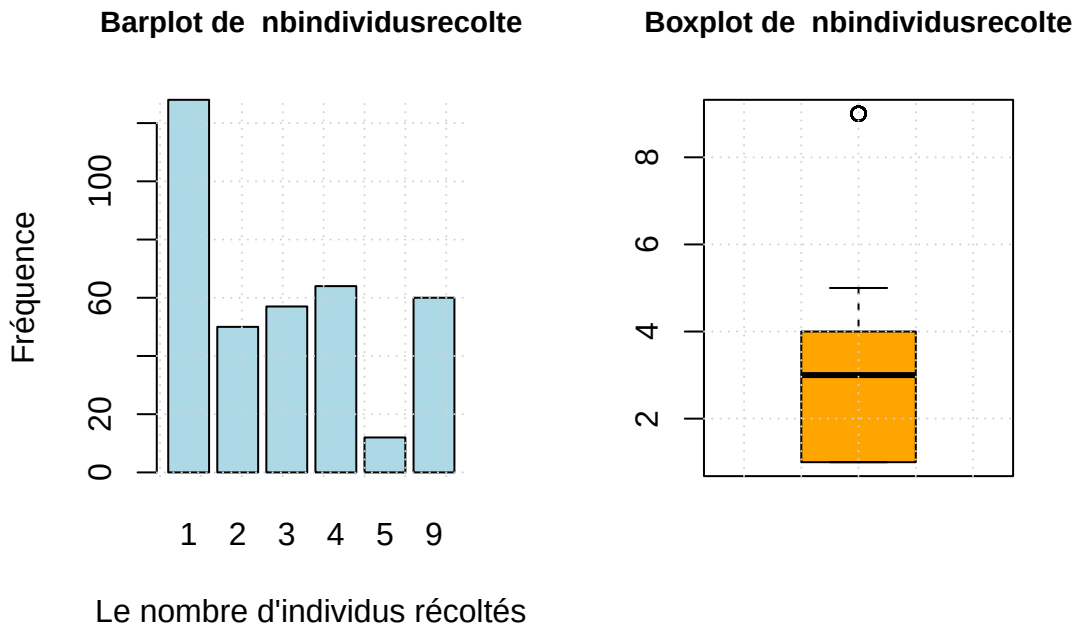

FIGURE 1 – Barplot et Boxplot du nombre d'individus récoltés

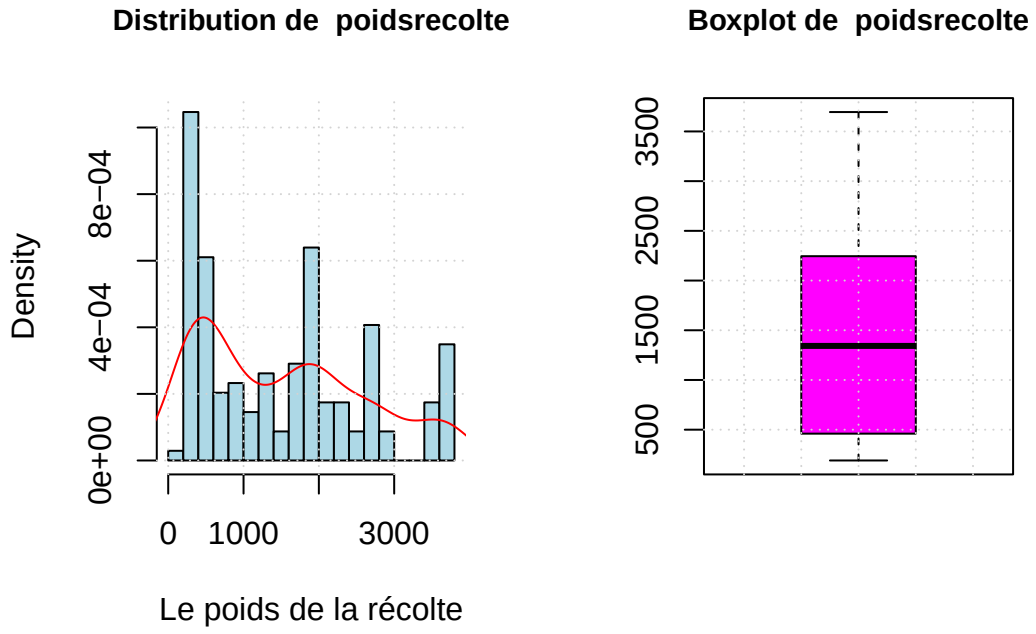

FIGURE 2 – Distribution et Boxplot du poids de la récolte

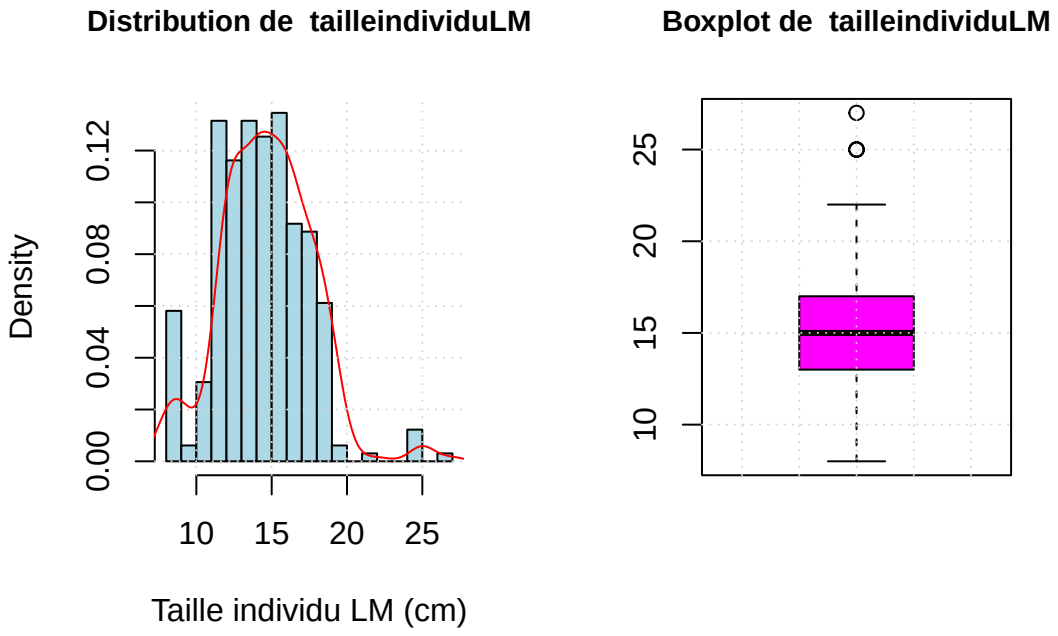

FIGURE 3 – Distribution et boxplot de la taille de l'individu (LM)

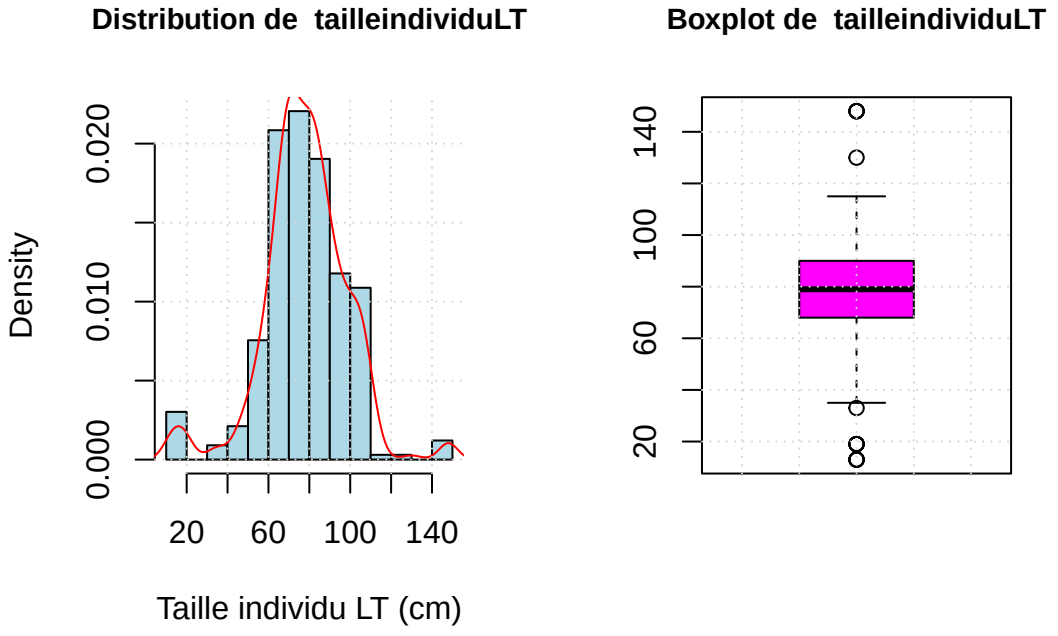

FIGURE 4 – Distribution et Boxplot de la taille de l'individu (LT)

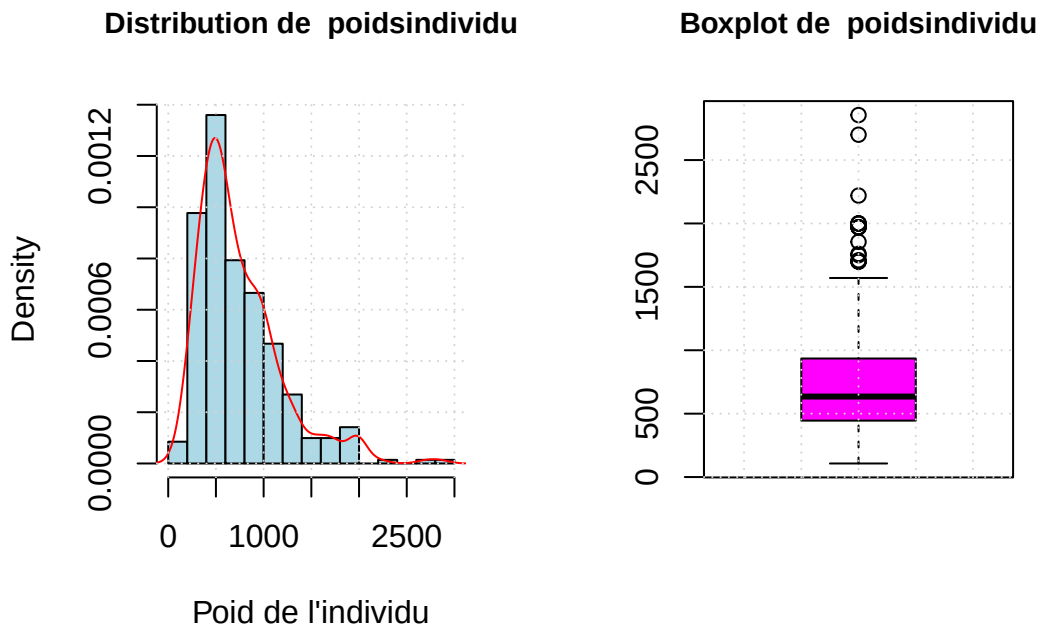

FIGURE 5 – Distribution et Boxplot du poids de l'individu

La distribution de la figure @ref(fig :figure5) est asymétrique à droite. Quelques individus beaucoup plus lourd que la majorité sont visible sur le boxplot. Il me semble que ce soit des individus atypiques. La médiane me semble autour de $600g$.

Les valeurs sur la figure @ref(fig :figure6) sont surtout entre 93 et 112 d'après l'intevalle interquartile du boxplot. La distribution est assez équilibrée, avec une médiane au alentour de 108. On observe deux modes révélant peut-être deux sous population.

On observe clairement sur la figure @ref(fig :figure7) deux modes, ce qui suggère peut-être deux périodes où la hauteur basse de la mer fluctue. Ces hauteurs se situent majoritairement entre 2 cm et 4 cm et entre 4 cm et 6 cm. La médiane est d'environ 4 cm et aucune valeur extrême n'est observée.

La majorité des durées d'enquête se situe entre 5 et 10 si on se fie à l'intervalle interquartille (@ref(fig :figure7)), avec une médiane autour de 6. Le boxplot montre une valeur atypique vers 20, indiquant une enquête exceptionnellement longue.

On aperçoit sur la figure @ref(fig :figure17) la distribution de la variable dérivée durée. La majorité des valeurs se situe autour de 100 à 140, avec quelques valeurs extrêmes plus faibles et plus élevées visibles sur le boxplot.

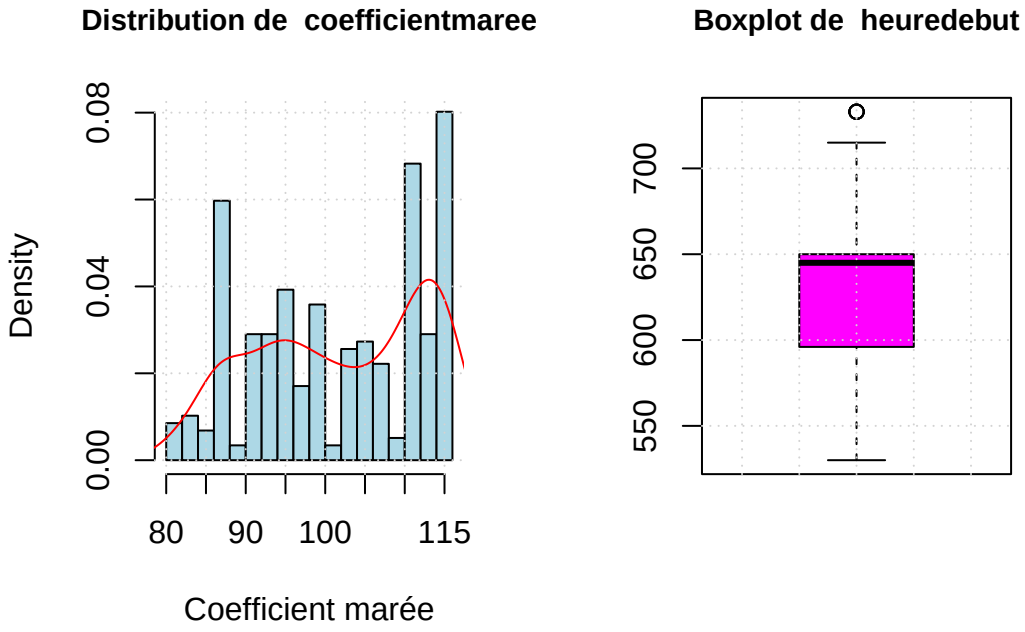

FIGURE 6 – Distribution et Boxplot du coefficient de la marée

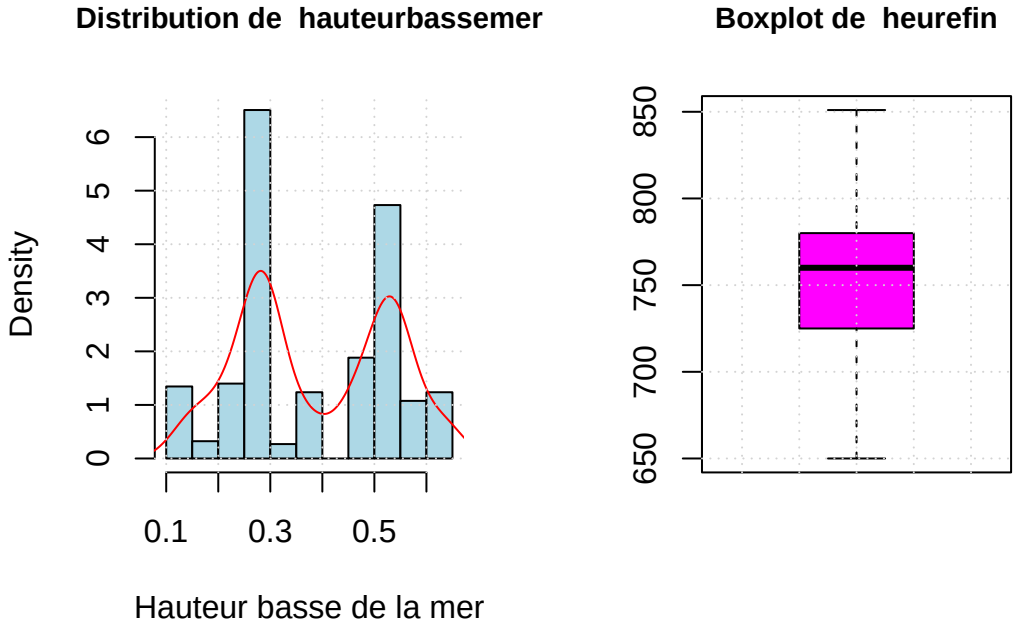

FIGURE 7 – Distribution et Boxplot de la hauteur basse de la mer

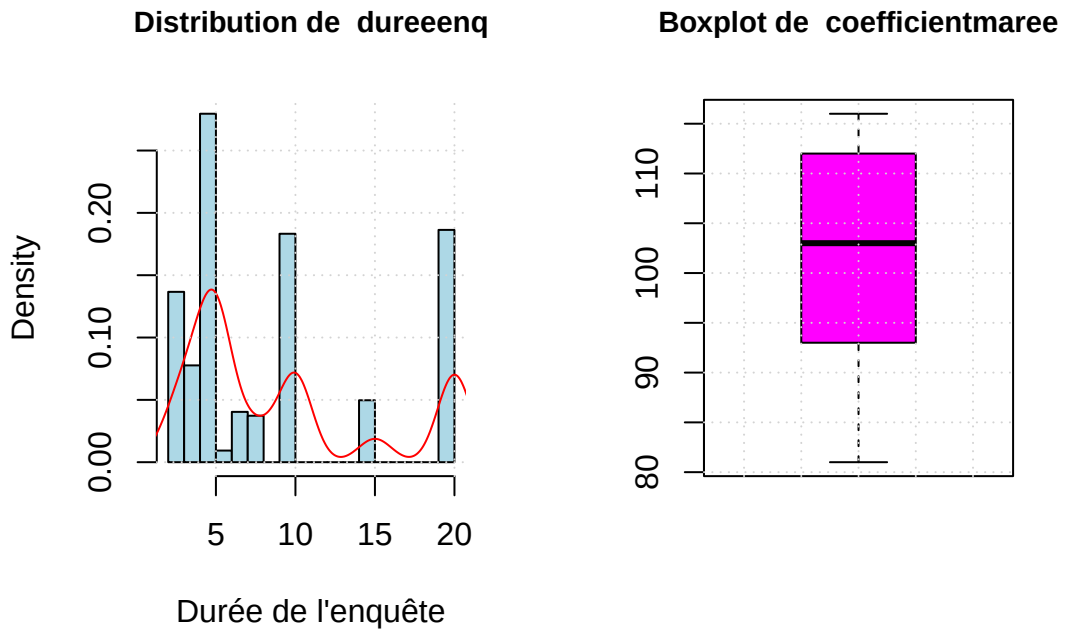

FIGURE 8 – Distribution et Boxplot de la durée de l'enquête

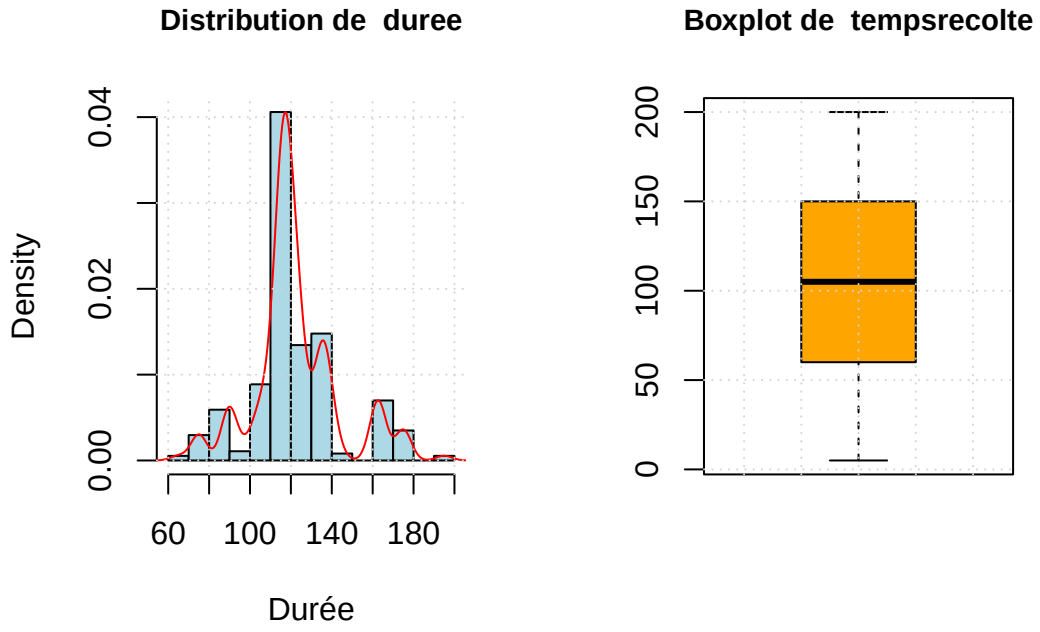

FIGURE 9 – Distribution et Boxplot de la durée

2.2. Distribution des NA et détection des outliers

Dans cette partie, nous allons examiner la distribution des valeurs manquantes des variables quantitatives. Nous tenterons ensuite de détecter d'éventuelles valeurs aberrantes par la méthode du **Z-score**.

Le Z-score d'une valeur x_i dans une variable X est définit :

$$Z(x_i) = \frac{x_i - \mu}{\sigma}$$

où,

- $\mu = \mathbb{E}[X]$ la moyenne de X.
- σ l'écart-type de X

$Z(x_i)$ mesure combien d'écart-types la valeurs x_i est éloignée de la moyenne.

Une valeur x_i est considérée comme aberrante si $\mid Z(x_i) \mid > 3$.

Quand les données ne sont pas gaussiennes, on préfère des mesures robustes de la variabilité. De ce fait, nous utiliserons un estimateur robuste de l'ecart-type :

MAD (Median Absolute Deviation) :

$$MAD = 1.483 \times median(\mid x_i - median(x_i) \mid)$$

Le Z-score robuste est définit :

$$Z_i^{rob} = \frac{x_i - median(x)}{\hat{\sigma}_{rob}}$$

où $\hat{\sigma}_{rob}$ peut être **MAD** ou un autre estimateur robuste de l'écart-type.

Les fonctions utilisées pour la détection des valeurs aberrantes, à savoir MAD, Z_rob et detect_outlier, sont décrites ici de manière conceptuelle. Leur code complet est fourni en annexe A.

Pour la variable *TailleindividuLM* (resp. *TailleindividuLT*), on constate que les outliers détectés, 27 et 25 (resp. 130, 148, 19 et 13), correspondent exactement à ceux affichés sur le boxplot de la figure 3 (resp. figure 4).

La figure @ref(fig :figure10) affiche la distribution des valeurs manquantes de toutes les variables. On constate que les variables *nbenfants*, *nbfemmespec* et *poidsrecolte* ont plus de 200 valeurs manquantes. Cela indique que ces variables sont les plus affectées. Les autres variables présentent un nombre plus faibles de valeurs manquantes.

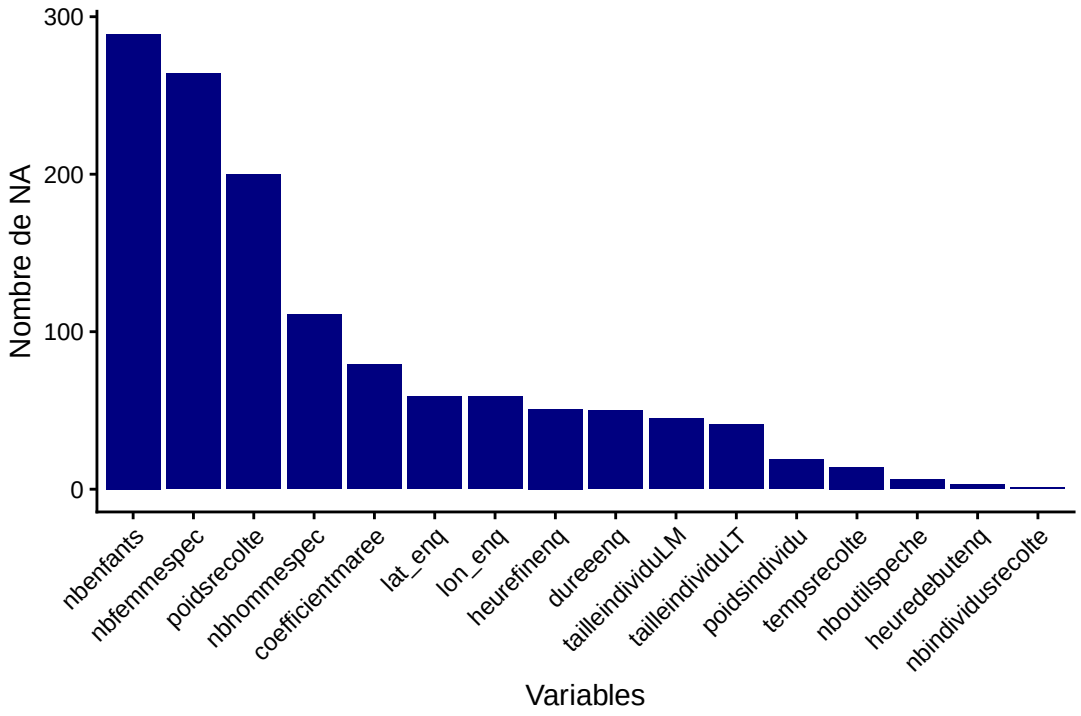

FIGURE 10 – Barplot du nombre de NA par variable

3. Analyses descriptives bivariées

Le graphique de la **figure 11** (En annexe D) affiche la matrice de corrélation et permet d'observer les relations entre les différentes variables. Les couleurs bleues indiquent une corrélation positive, tandis que les couleurs rouges indiquent une corrélation négative.

On observe notamment une corrélation positive entre le nombre d'individus récoltés et le poids de la récolte. De même, la taille et le poids des individus sont positivement corrélés. En revanche, certaines variables présentent des corrélations faibles, indiquant des relations limitées entre elles.

4. Analyses descriptives multidimentionnelles

Dans cette partie, nous allons procéder à une analyse de données multidimensionnelle, à savoir l'analyse en composantes principales (ACP). Il s'avère être une bonne approche pour étudier toutes les variables en même temps. L'ACP consiste à chercher des liaisons bivariées entre les variables simultanément en réduisant le nombre de dimensions des données de départ. Autrement dit, on cherche des axes principaux qui résumeent au mieux les données tout en gardant le maximum d'information.

Il est important de noter que dans le package **Factoshiny**, il est possible de gérer les données manquantes en ACP. Il maximise la log-vraisemblance du modèle

$$x^j = \mu_j + \sum_{k=1}^{K} a_{jk} z^k + \epsilon^j, \text{ avec } \epsilon^j \sim \mathcal{N}(0, \sigma^2 I)$$

Ensuite, minimise le critère $||X^c - AZ||^2$ avec $AZ = \hat{X}^c$, et réitère le procéssus jusqu'à convergence.

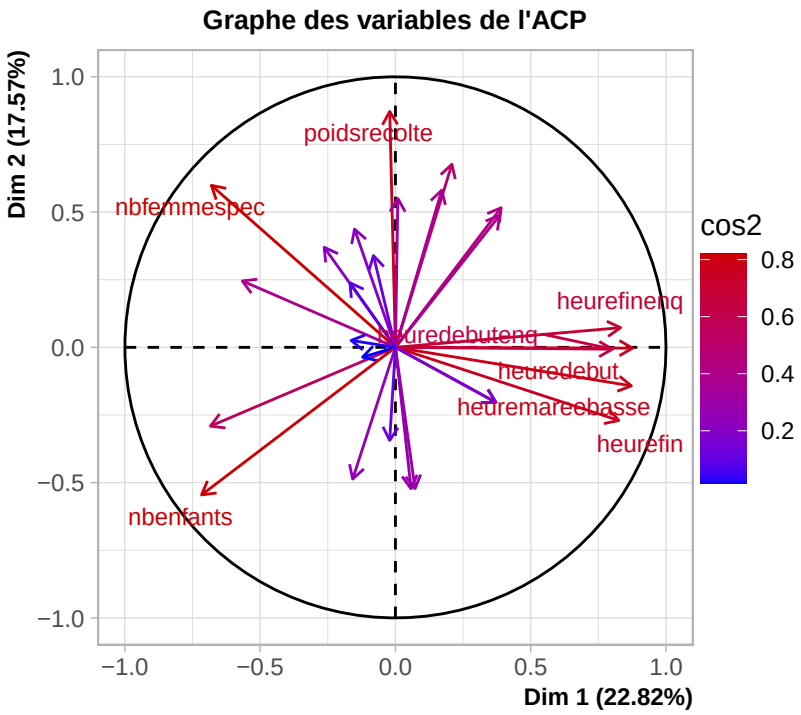

FIGURE 11 – Graphe des variables dans le plan(1,2)

Sur *la figure 11* les variables horaires, formant le groupe 1 sont fortement corrélés à le premier axe factoriel. En opposition au groupe 1, on retrouve la variable *nbfemmespec* dans le quadrant supérieur gauche et la variable *nbenfants* dans quadrant inférieur gauche. Les variables du groupe 1 ont une direction similaire, ce qui est logique puisqu'elles mesurent presque la même chose, explicant ainsi leurs fortes corrélations.

La deuxième axe factoriel est principalement corrélé à la variable *poidsrecolte*. Celle-ci semble ne pas avoir de relation avec le groupe 1. En effet, le cos^2 formée entre *poidsrecolte* avec le groupe 1 est proche 0.

Les individus de *la figure 12* qui sont les mieux représentés sur le plan factoriel (cos^2 élevés) se situent majoritairement dans le quadrant inférieur gauche. Leur position indique une association positive avec la variable *nbenfants*, située dans la même direction sur le cercle des corrélations. Les individus *306* et *307* se situent dans le quadrant inférieur à droit et ont une association positive avec les variables hauraires. On observe que l'idividu *10* se retrouve très loin du centre de gravité, suggérant peut-être une valeur atypique ou aberrante.

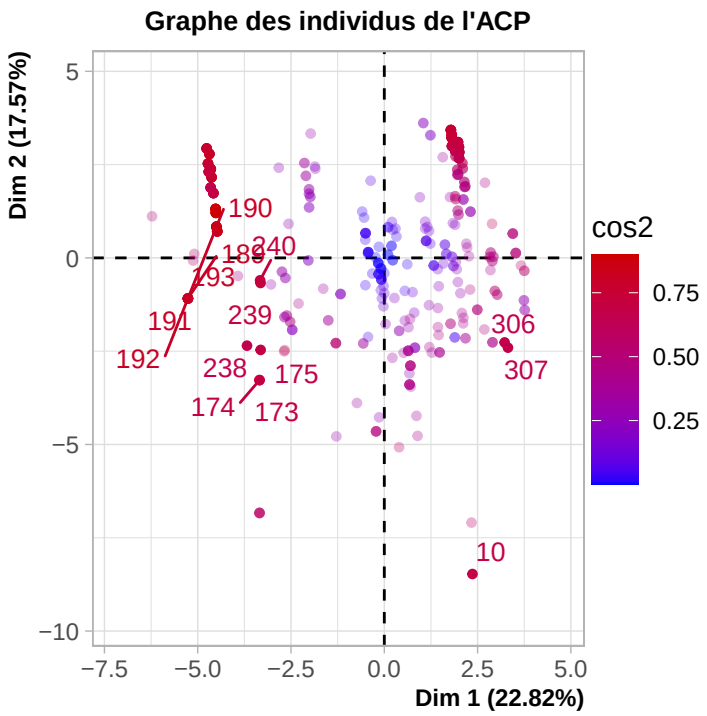

FIGURE 12 – Graphe des individus dans le plan(1,2)

On constate également que le premier plan factoriel capture 40.39% de l'inertie totale, ce qui signifie qu'il explique 40.39% de la variabilité totale des données.

On peut voir sur *la figure 13* les variables projetées sur le plan factoriel (Dim 2, Dim 3), elle met principalement en évidence trois variables. La variable *poidsrecolte* ayant une corrélation positive avec les variables *nbpecheurrecolte* et *dureenq* selon l'axe 2.

Le graphe des individus (*la figure 14*) dans le plan (Dim 2, Dim 3) montre que les observations sont majoritairement réparties dans le quadrant supérieur gauche. Ces individus sont très loin du centre de gravité, laissant penser qu'elles sont atypiques. Par ailleurs, l'individu *10* fais partie de ce groupe, renforçantt ainsi l'idée qu'il est atypique.

5. Analyses descriptives pour les variables qualitatives

Comme pour les variables quantitatives, nous procédons aux analyses des variables qualitatives. Nous commencerons par des visualisations élémentaires (diagrammes en barres) pour chacune de ces variables. Ensuite, nous analyserons les relations entre modalités en regardant les écarts à la moyenne typé à l'aide de tableaux de contingence. Enfin, nous ferons une analyse des correspondances multiples (ACM) afin d'explorer la structure multidimensionnelle des relations entre modalités..

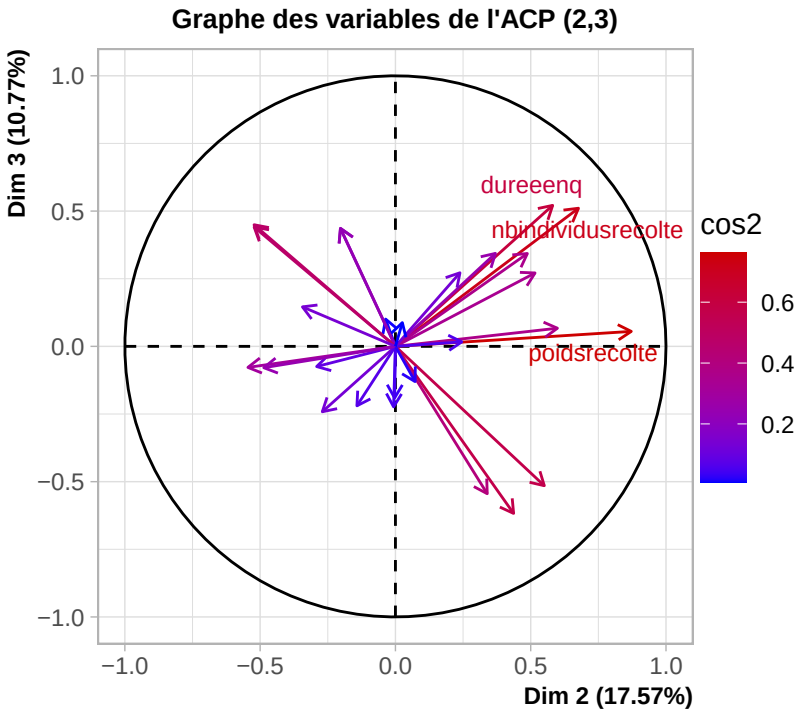

FIGURE 13 – Graphe des variables dans le plan(2,3)

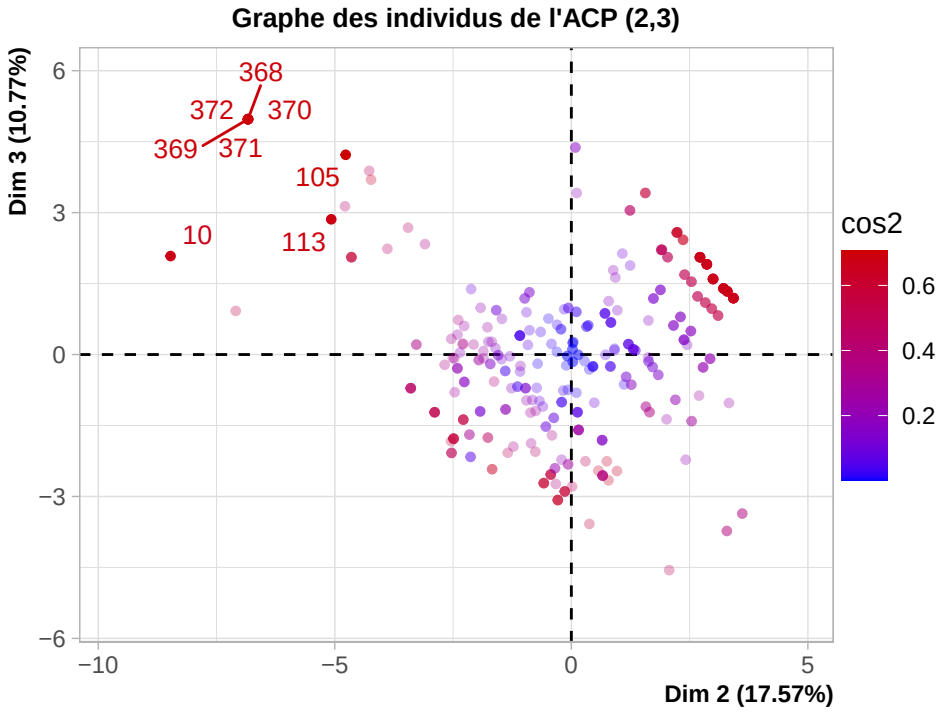

FIGURE 14 – Graphe des individus dans le plan(2,3)

5.1. La distribution des modalités

5.2. Relation d'indépendance

Dans cette partie, nous construisons un graphique représentant les écarts à l'indépendance entre les modalités des variables. Ce graphique permet d'identifier, de manière exploratoire, les associations éventuelles entre les variables qualitatives. Le script permettant de générer ce graphique est présenté en annexe.

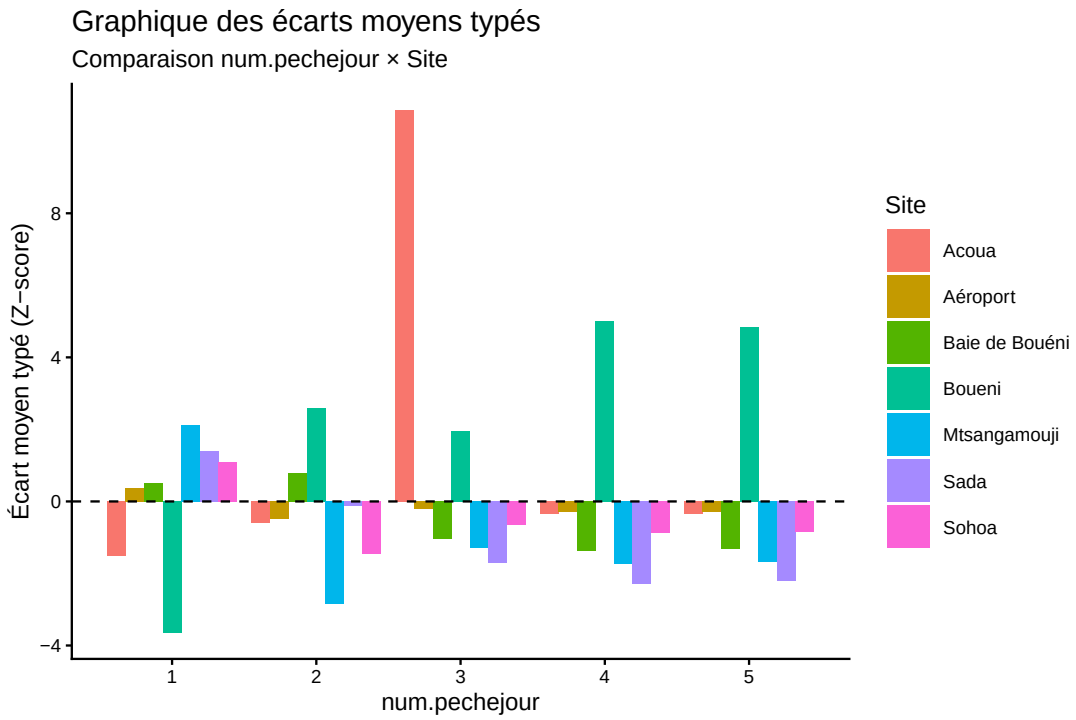

FIGURE 15 – les écarts à l'indépendance entre num.pechejour et Site

Une valeur positive indique que la combinaison de modalités apparaît plus souvent que ce que l'on attendrait sous l'hypothèse d'indépendance. Une valeur négative indique au contraire que cette combinaison apparaît moins souvent que prévu.

Par exemple, pour la colonne correspondant à *num.pechejour = 3*, la comparaison avec *Site = Acoua* (barre rose) montre un écart fortement positif, indiquant que la combinaison de ces modalités apparaît plus souvent que ce que l'on attendrait sous l'hypothèse d'indépendance.

5.3. Analyse de corespondances multiples

6. Annexe

L'annexe B présente un tableau récapitulatif de toutes les variables quantitatives, précisant type (continues ou discrètes), leurs unités ainsi que la présence éventuelle de valeurs manquantes.

On retrouve en annexe C un tableau similaire à celui de l'annexe B, mais consacré aux variables qualitatives.

6.1. Annexe A : Les fonctions codées

Dans cette annexe vous trouverez toutes les fonctions utiles programmées afin de faciliter l'analyse et le nettoyage préliminaire des données.

6.1.1. plt_hist_uni

La fonction plt_hist_uni affiche un histogramme pour les variables quantitative continue et rajouter sa densité en rouge. Elle utilise 6 arguments :

- df : Un tableau contenat les variables quantitatives ;
- br : Sert à définir la manière dont les données seront découpées en classes dans la fonction hist ;
- nom : Contient tout les noms des variables présentes dans df ;
- Xlab : Sert à définir le titre de l'axe des x ;
- cex : définit la taille du titre du graphique ;
- k : Permet de choisir la variable que l'on souhaite analyser.

```r
# histogramme et ajout de la densite
plt_hist_uni <- function(df, br = 20, nom = noms_quant,
                         xlab = "Durée (minutes)", cex = 0.9, k = 1){
  # histograme
  hist(df[[nom[k]]],
     freq = F,
     breaks = br,
     col = "lightblue",
     main = paste("Distribution de ",nom[k]),
     xlab = paste(xlab),
     cex.main = cex)

  # la densite
  lines(density(df[[nom[k]]], na.rm = TRUE),
     col = "red")
  grid()
}
```

6.1.2. plt_bar_uni

La fonction plt_bar_uni renvoie un diagramme en barres pour les variables quantitatives discrètes. Elle utilise 5 arguments (df, nom, xlab, cex et k) ayant des rôles similaire à ceux de la fonction plt_hist_uni.

```
# barplot
plt_bar_uni <- function(df, nom = noms_quant,
                        xlab = "Le nombre d'individus récoltés",
                        cex = 0.9, k = 1){
    barplot(table(df[[nom[k]]]),
     col = "lightblue",
     main = paste("Barplot de ",nom[k]),
     xlab = paste(xlab),
     ylab = "Fréquence",
     cex.main = cex)
  grid()
}
```

6.1.3. box_plt_uni

La fonction box_plt_uni permet de représenter la distribution d'une variable quantitative à l'aide d'un boxplot. Elle permet de visualiser la médiane, quartiles et les outliers (valeurs atypiques ou aberrantes).

```
# boxplot
box_plt_uni <- function(df, nom = noms_quant, col = "orange",
                        cex = 0.9, k = 1){
  boxplot(df[[nom[k]]],
        col = col,
        main = paste("Boxplot de ", nom[k]),
        cex.main = cex)
  grid()
}
```

6.1.4. MAD

La fonction MAD est une estimation robuste de l'écart-type. Elle prend deux arguments, un vecteur (x) et un paramètre (c) qui sert à mettre le MAD sur la même échelle que l'écart-type pour une distribution normale.

```
# MAD (Median Absolute Deviation)
MAD <- function(x, c= 1.483){
  n <- length(x)

  #  vec abs(x\_i - mediane(x))
  re <- sapply(1:n, function(i){
```

```
    return(abs(x[i] - median(x, na.rm = T)))
  })

  return(c*median(re, na.rm = T))
}
```

6.1.5. Z_rob

La fonction Z_rob n'est rien d'autre qu'une fonction calculant un Z-score, dans laquelle la moyenne est remplacée par la médiane et l'écart-type par son estimation robuste, le MAD.

```
Z_rob <- function(x, s = MAD(x)){
  n <- length(x)

  #  vec (x\_i - mediane(x))
  re <- sapply(1:n, function(i){
    return(x[i] - median(x, na.rm = T ))
  })

  return(re/s)
}
```

6.1.6. detect_outlier

La fonction detect_outlier calcule un Z-score robuste pour une variable donnée, puis identifie les valeurs dont le Z-score absolu dépasse un seuil (par défaut 3). Elle retourne les valeurs détectées, en tenant compte des NA.

```
# detection d'outliers (aberrantes, atypiques)
detect_outlier <- function(df= df_quant, nom= noms_quant, k=1){

  # z-score robuste
  z_rob <- Z_rob(df[[nom[k]]])

  # Identifier les index des outliers
  outliers <- which(abs(z_rob) > 3)

  # afficher les outliers
  unique(df[[nom[k]]][outliers])
}
```

6.2. Annexe B : Description des Variables quantitatives

Variable	Description	Type	Unité	Valeurs manquantes
nbindividusrecolte	Nombre d'individus récoltés	Discrète	nombre	Oui (0.269%)
poidsrecolte	Poids total de la récolte	Continue	kg	Oui (53.763%)
tailleindividuLM	Taille individuelle (LM)	Continue	cm	Oui (12.097%)
tailleindividuLT	Taille individuelle (LT)	Continue	cm	Oui (11.022%)
poidsindividu	Poids d'un individu	Continue	g	Oui (5.108%)
heuredebut	L'heure de départ	Continue	min	Non
heurefin	L'heure de la fin	Continue	min	Non
coefficientmaree	Coefficient de marée	Continue	–	Oui (21.237%)
heuremareebasse	L'heure de la basse mer	Continue	min	Non
hauteurbassemer	Hauteur de basse mer	Continue	m	Non
heuredebutenq	L'heure du début de l'enquête	Continue	min	Non
dureeenq	Durée de l'enquête	Continue	min	Oui (13.441%)
nbhommespec	Nombre d'hommes pêchant	Discrète	nombre	Oui (29.839%)
nbfemmespec	Nombre de femmes pêchant	Discrète	nombre	Oui (70.968%)
nbenfants	Nombre d'enfants	Discrète	nombre	Oui (77.688%)
nbpecheurstotal	Nombre total de pêcheurs	Discrète	nombre	Non
tempsrecolte	Temps de récolte	Continue	min	Oui (3.763%)
nbpecheursrecolte	Nombre de pêcheurs récoltant	Discrète	nombre	Non
nboutilspeche	Nombre d'outils de pêche	Discrète	nombre	Oui (1.613%)
heuredebut	Durée	Continue	min	Non
heurefin	Durée	Continue	min	Non
duree	Durée	Continue	min	Non
lat_debut	Latitude de début	Continue	degrés	Non
lon_debut	Longitude de début	Continue	degrés	Non
lat_fin	Latitude de fin	Continue	degrés	Non
lon_fin	Longitude de fin	Continue	degrés	Non
lat_enq	Latitude de l'enquête	Continue	degrés	Oui (15.86%)
lon_enq	Longitude de l'enquête	Continue	degrés	Oui (15.86%)

Table 1 – Tableau récapitulatif des variables quantitatives

6.3. Annexe C : Description des Variables qualitatives

Variable	Modalités	Valeurs manquantes
Libelle.de.sortie	89 modalités	Non
num.pechejour	1, 2, 3, 5, 4	Non
especepechee	Poulpe de récif commun	Non
outilcapture	FID4.1, FID4.2, PSM2, FIE1	Oui (10.215%)
num.individus	1, 2, 8, 7, 4, 5, 6, 9, 3	Non
categtailleindividu	Sup 10cm, Inf. 10cm	Oui (18.28%)
sexeindividu	Male, Femelle, Non renseigné	Oui (5.645%)
etatindividu	Vide, Entier	Oui (16.935%)
maturiteindividu	Non renseigné, Stade II	Oui (90.591%)
Type.de.suivi	Enquêtes	Non
Protocole	Enquête pêche à pied	Non
Version	Version 2023	Non
Etat	Validée, Terminée	Non
Organisme.Createur	PNMM, Ocea Consult	Non
Createur	5 créateurs	Non
Dernier.intervenant	J.Cyrielle, M.Lenaig	Non
Territoire	Mayotte	Non
Code.Site	7 codes sites	Non
Site	7 sites	Non
joursemaine	Lu, Ma, Me, Je, Ve, Sa, Di	Non
periode	Semaine, Vacances, Week-end_Jour.Férié	Non
ramadan	Non, Oui	Oui (100%)
referentsortie	12 référents	Oui (0.538%)
equipeterrain	30 équipes	Oui (0.538%)
couverturenuageuse	0–25%, 25–75%, 75–100%	Oui (20.699%)
precipitations	Pas_précipit, Pluie fine, Pluies éparses	Oui (20.699%)
forcevent	6 modalités	Oui (0.806%)
turbidite	Claire	Non
enqueteur	12 modalités (max)	Oui (48.118%)
observations	papa ediamine	Oui (99.731%)
destinationpeche	Perso, Non renseigné, Offert	Oui (23.925%)
prixpeche	NA	Oui (100%)
connaissancequota	Non, Non renseigné, Oui	Oui (0.269%)
connaissanceregengin	Non, Non renseigné, Oui	Non
connaissanceregtaillemin	Non, Non renseigné, Oui	Non
connaissanceregfermeture	Non, Non renseigné, Oui	Non
connaissanceregvente	Non, Non renseigné, Oui	Non
paniervide	Non, Oui	Oui (0.538%)
francais	Non, Oui	Oui (13.172%)
num.pratiquejour	1, 3, 2	Non
outilspeche	FID4.1, PSM2, LHP1, FID4.2, FIE1	Non

Table 2 – Tableau récapitulatif des variables qualitatives ayant au moin une valeur

6.4. Annexe D : Autres visualisatons

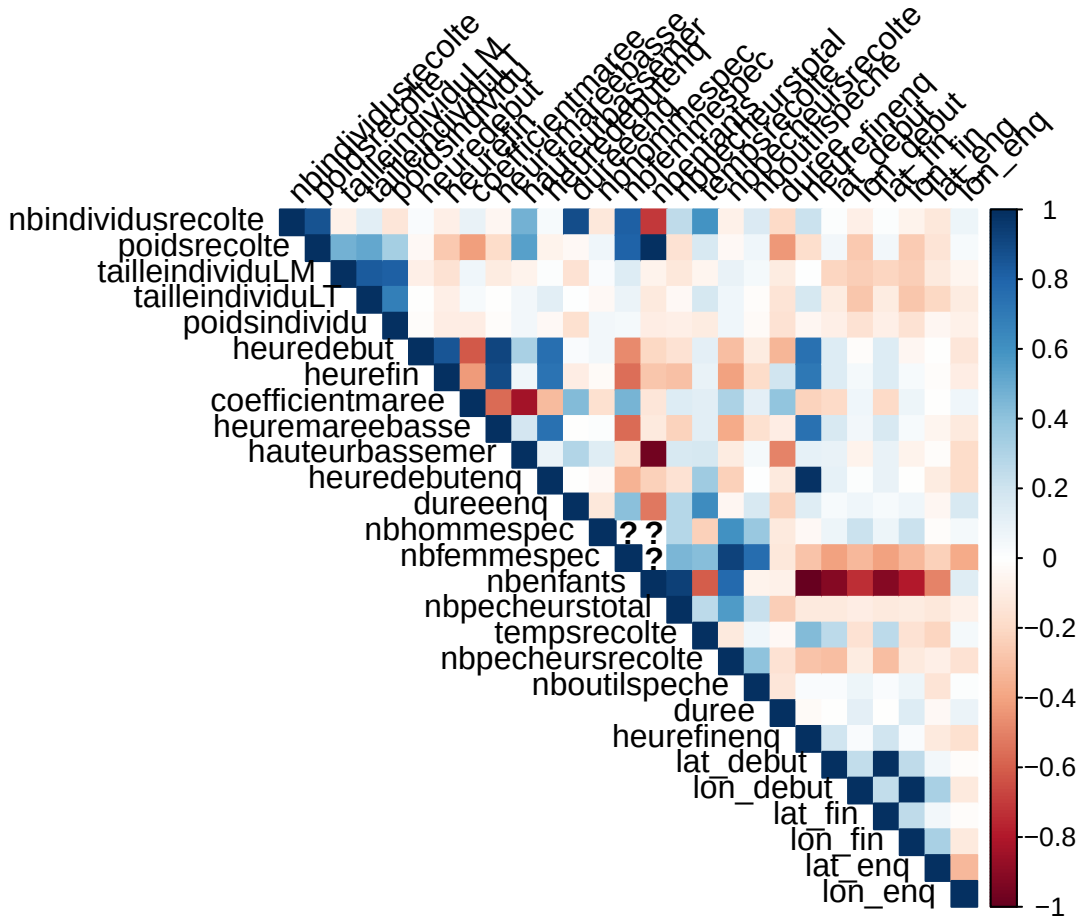

FIGURE 16 – Corrélations entre les variables