UNIVERSITÉ DE MAYOTTE

IMAG
INSTITUT MONTPELLIERAIN ALEXANDER GROTHENDIECK

Revue bibliographique et exploration des données

Réalisé par :
ATTOUMANI Ibrahim

Année universitaire 2025 – 2026

STATISTIQUE
SCIENCE DES DONNÉES BIOSTATS
UNIVERSITÉ DE MONTPELLIER

Contexte

Pour concevoir des modèles statistiques robustes et obtenir des résultats significatifs, il est important de bien connaître le sujet d'étude.

Il est également essentiel de nettoyer les données de manière rigoureuse, afin d'obtenir des variables riches tant sur le plan temporel que spatial.

Sommaire

Les objectifs

- Contexte scientifique
- Les données

Définitions et Exemple

- Modèle Hiérarchique
- Surdispersion
- Modèle d'abondance

Exploration des données

- Analyses descriptives élémentaires
- Analyses Multidimensionnelles
- Questions méthodologiques critiques

Conclusion

Les objectifs

Les objectifs à atteindre

- Objectif 1: Contexte scientifique et revue bibliographique
- Objectif 2 : Exploration et compréhension des données

Contexte scientifique

Les modèles actuels étudient la dynamique des populations, mais intègrent peu les pressions humaines.

Il est nécessaire de développer des approches combinant à la fois les facteurs environnementaux et les impacts des activités humaines.

Structure des données

Observations : 372

Variables : 82 (quantitatives, qualitatives, temporelles)

Données manquantes : 18,97%

Classes : données partagées en 3 catégories

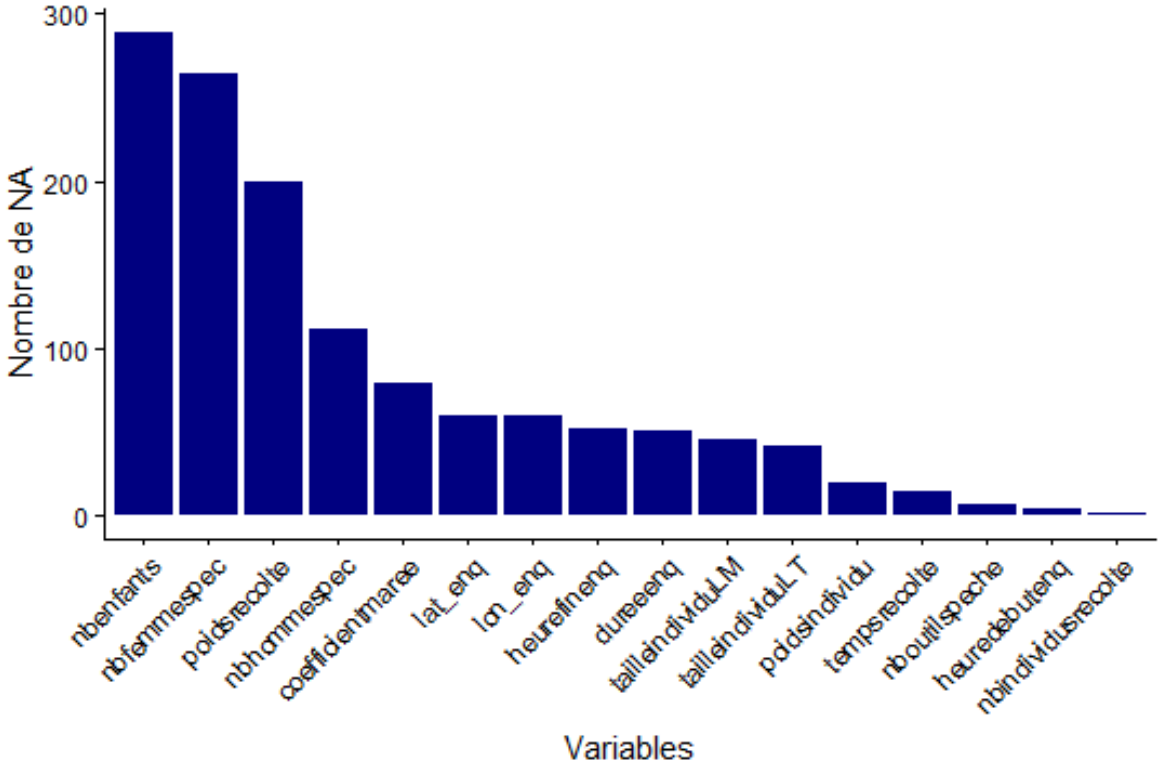

Figure 1: Distribution des valeurs manquantes

Variables quantitatives

372 observations de 27 variables

Continue : *tailleindividuLM*, *poidsindividus*, ...

Discrète : *nbpecheurstotal*, *nbindividusrecolte*, ...

Création de variables : *duree*, *dureeenq*

Conversion des variables horaires en minutes

nbindividusrecolte	tailleindividuLM	poidsindividus	nbpecheurstotal
1	13	975	1
1	13	795	1
2	8	230	1
2	12	240	1

Table 1: Extrait des variables quantitatives

Variables qualitatives

Données initiales : 372 obs. of 50 variables

Variables qualitatives nominales : *Site*, *Ramadan*

Variable qualitative ordinale : *Précipitations*

Sélection des variables informatives utiles à la modélisation

Après sélection : 372 obs. of 26 variables

Site	Ramadan	Précipitations
Boueni	Non	Pas de précipitation
Sada	Non	Pluie fine
Sada	Non	Pluie fine
Mtsangamouji	Non	Pluie fine

Table 2: Extrait des variables qualitatives

Modèle Hiérarchique

Modèle hiérarchique et surdispersion

Soit $Y \mid \theta \sim P_\theta$ une variable de moyenne $\mu = \mathbb{E}(Y)$ et de variance $\mathrm{Var}(Y)$.
Si de plus, $\theta \sim P_\lambda$, on parle de **modèle hiérarchique**.
On parle de surdispersion lorsque

$$\mathrm{Var}(Y) > \mathrm{Var}_{P_\theta}(Y),$$

c'est-à-dire lorsque la variance observée est supérieure à la variance attendue sous le modèle P_θ.

Modèles d'abondance

Soit $n_{it} \mid N_i \sim \mathcal{B}(N_i, p_{it})$

$N_i \sim \mathcal{P}(\lambda_i)$: paramètre latent représentant l'abondance

$\theta \sim P_\lambda$: hyperparamètres du modèle

Modèle hiérarchique : la variabilité de n_{it} est expliquée par N_i et λ_i

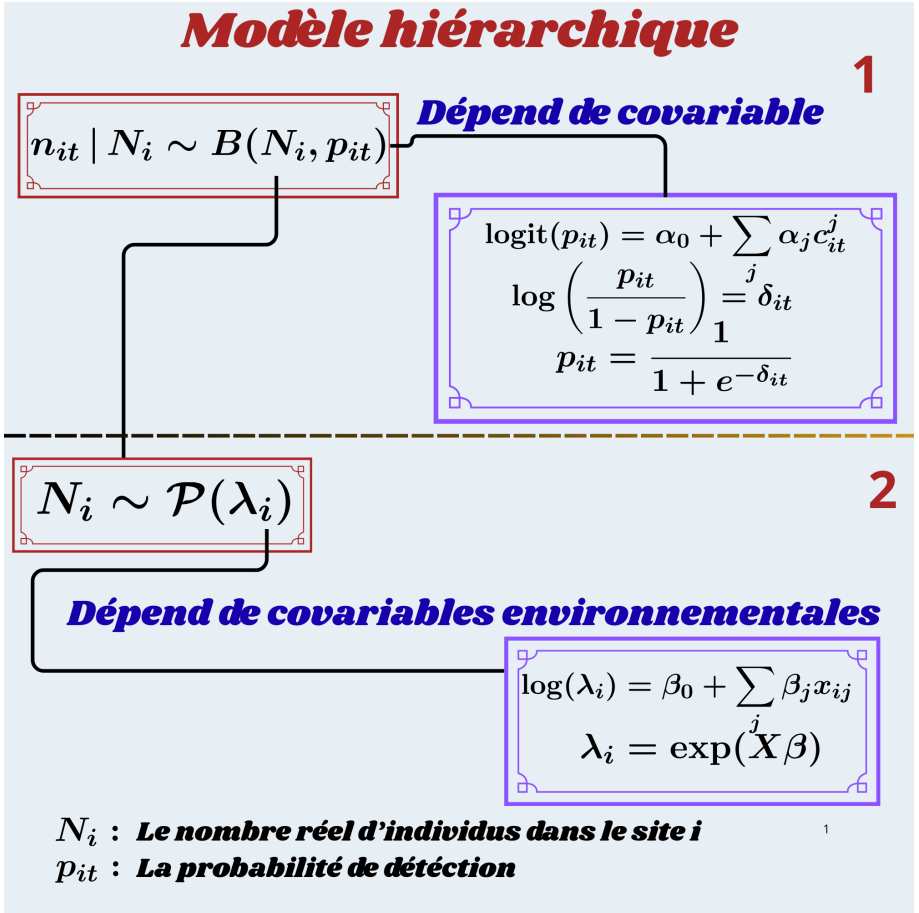

Figure 2: Schéma d'un modèle hiérarchique

Analyses descriptives élémentaires

La majorité des individus présente des tailles autour de 60 cm et 100 cm

La médiane se situe aux alentours de 70 cm

Quelques valeurs atypiques sont présentes, mais restent plausibles

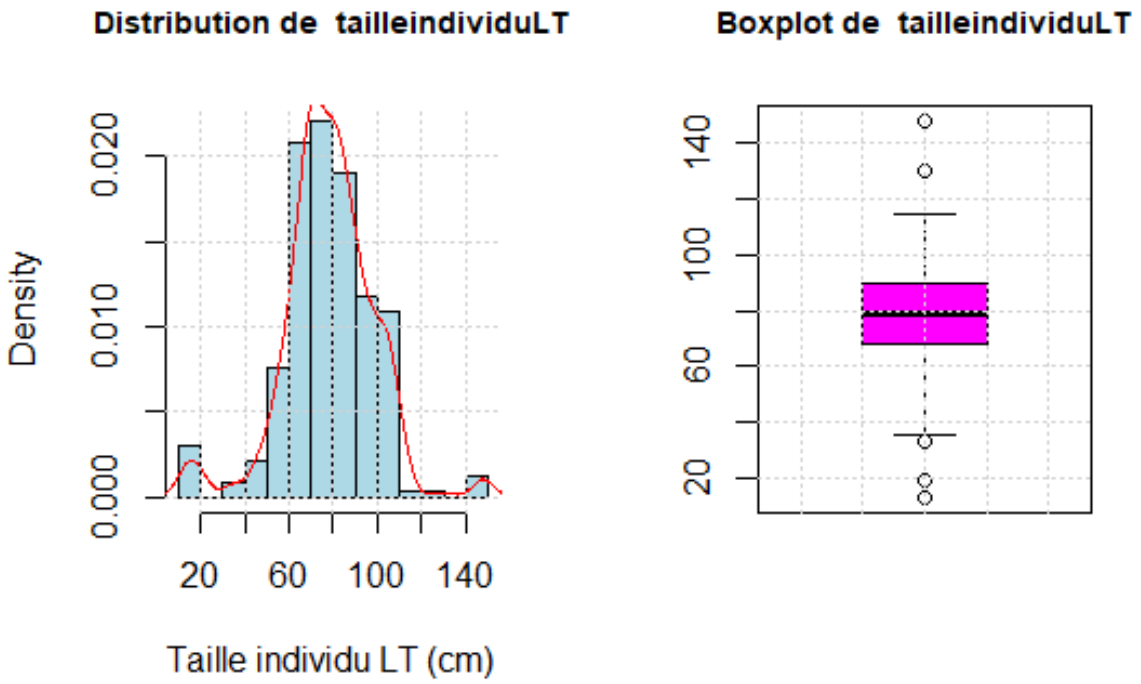

Figure 3: Distribution et boxplot de la taille de l'individu (LT)

Relation d'indépendance

Valeur positive $\longrightarrow$ combinaison plus fréquente que prévu

Valeur négative $\longrightarrow$ combinaison moins fréquente que prévu

Exemple : *num.pechejour* = *3* & *Site* = *Acoua* $\longrightarrow$ écart fortement positif

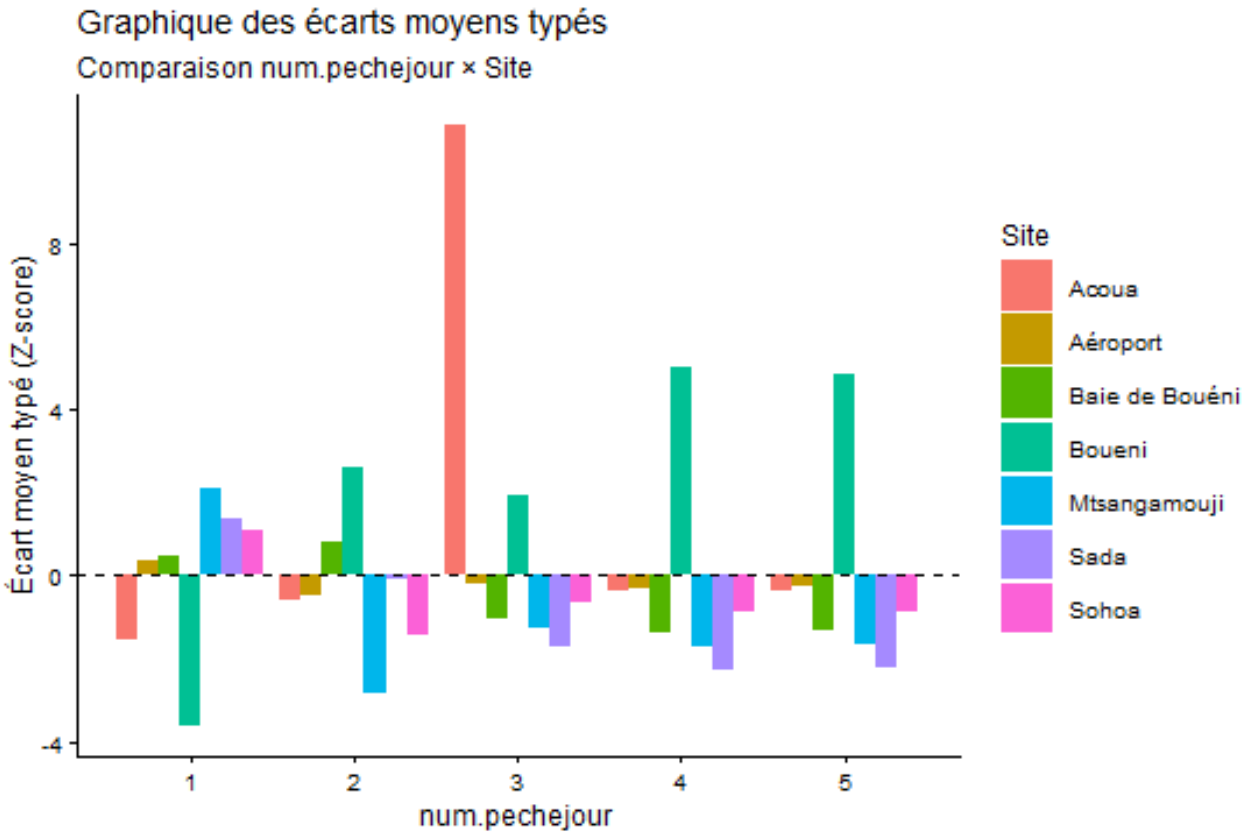

Figure 4: Relation d'indépendance entre *num.pechejour* et le *Site*

Analyses Multidimensionnelles (1/2)

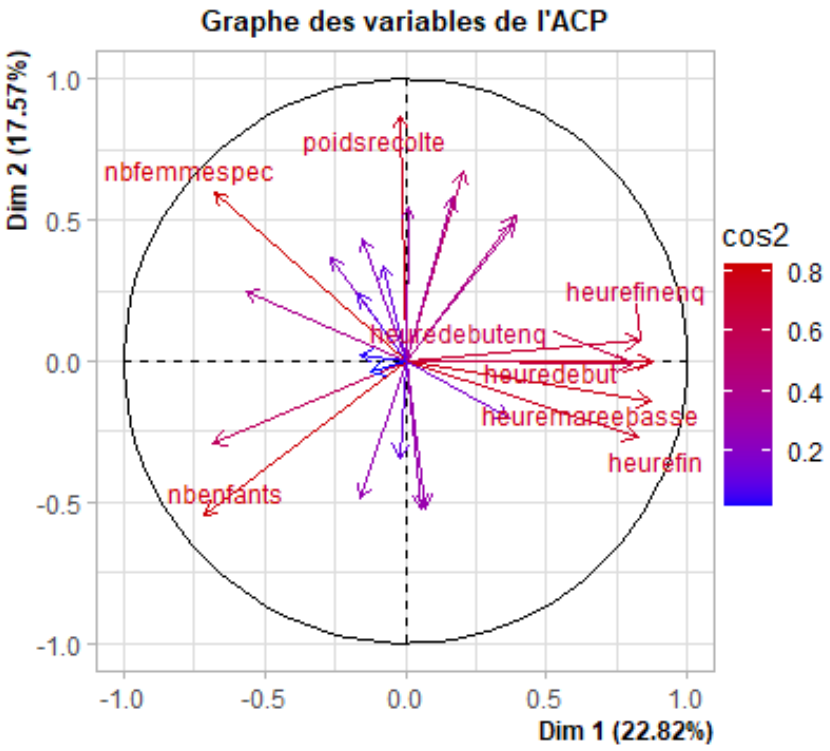

Figure 5: Variables dans le plan (1,2)

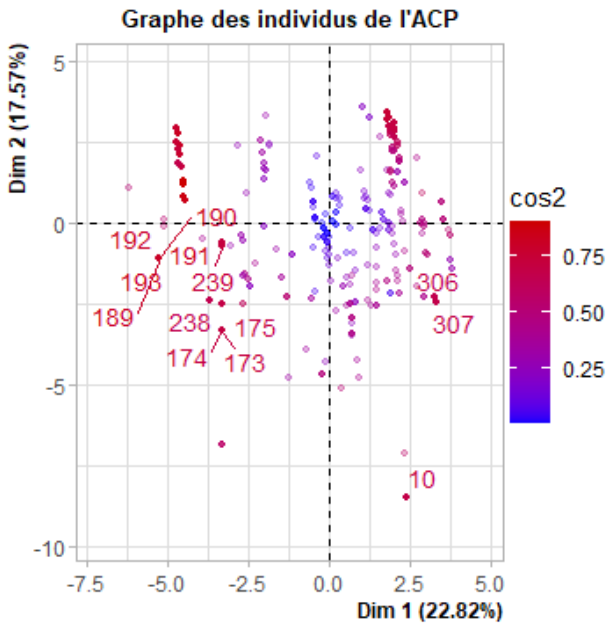

Figure 6: Individus dans le plan (1,2)

Analyses Multidimensionnelles (2/2)

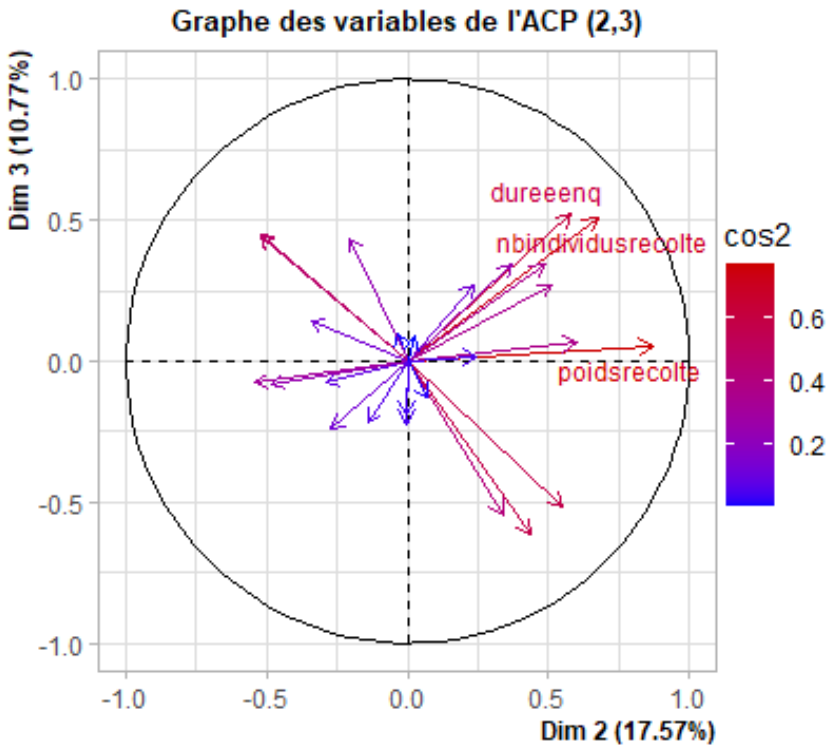

Figure 7: Variables dans le plan (1,3)

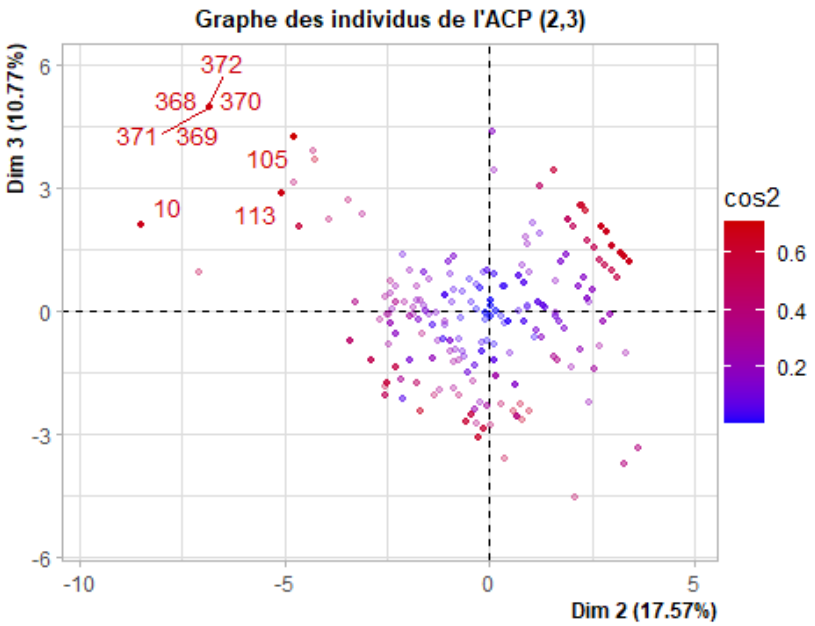

Figure 8: Individus dans le plan (1,3)

Questions méthodologiques critiques

- *Gestion des valeurs manquantes : imputation (ACP, Spline, EM, Régression)*
- *Prise en compte de la surdispersion*
- *Validité des hypothèses du modèle hiérarchique*
- *Validition croisée*
- *Modèle dynamique*

Conclusion

La revue bibliographique permet de définir un cadre solide

L'exploration des données montre des variables pertinentes et des patterns intéressants

Merci !

Pour votre attention et votre intérêt

ATTOUMANI Ibrahim