UNIVERSITÉ DE MAYOTTE

IMAG
INSTITUT MONTPELLIERAIN ALEXANDER GROTHENDIECK

Revue bibliographique et exploration des données

Réalisé par :
ATTOUMANI Ibrahim

Année universitaire 2025 – 2026

STATISTIQUE
SCIENCE DES DONNÉES BIOSTATS
UNIVERSITÉ DE MONTPELLIER

Contexte

Le modèle de Royle (2004) estime l'abondance à partir de comptages répétés, sous hypothèse de population fermée.

Il ne prend pas en compte explicitement les pressions anthropiques ni l'excès de zéros souvent observé dans les données.

Joseph et al. (2009) proposent des extensions (ZIP, ZINB) intégrant l'occupation et certaines hétérogénéités via des covariables.

Le modèle de Dail & Madsen (2011) permet de modéliser l'évolution temporelle de l'abondance.

Sommaire

Contexte et objectifs

Modèle de Royle

- Principe et estimation de l'abondance

Limites du modèle

- Excès de zéros
- Détection imparfaite
- Perte d'information (agrégation des données)

Extensions du modèle

- ZIP et ZINB (Joseph et al., 2009)
- Modèle dynamique (Dail & Madsen, 2011)

Données et variable d'intérêt

Conclusion

Les objectifs

Objectifs

- Comprendre le modèle de Royle et ses limites
- Étudier ses extensions (ZIP, ZINB, modèle dynamique)
- Analyser les données d'abondance

Modèle de Royle (1/2)

L'abondance ne peut pas être modélisée directement $\rightarrow$ c'est ça la structure hiérarchique

Nombres d'individus observés:

$$n_{it} \mid N_i \sim \mathcal{B}(N_i, p)$$

Abondance réelle inconnue (variable latente):

$$N_i \sim \mathcal{P}(\lambda_i), \quad \text{ou} \quad N_i \sim \mathcal{NB}(\mu_i, r)$$

λ_i : abondance moyenne au site i

p : probabilité de détection

Modèle de Royle (2/2)

Le modèle de Royle (2004) permet d'estimer l'abondance à partir de comptages répétés.

Il repose sur deux niveaux :

- Processus écologique : abondance réelle inconnue notée N_i
- Processus d'observation : nombres d'individus observés n_{it}

L'abondance est supposée constante durant les répétitions (population fermée).

Les observations dépendent d'une probabilité de détection.

Hiérarchie : N_i est latent, les observations n_{it} dépendent de N_i

Principe et estimation

Carroll et Lombard (1985)
$p \sim \text{Beta}(a, b)$, intégré $\rightarrow$ seul N_i reste inconnu Pas de covariables, pas de lien avec l'environnement

Royle (2004) – modèle hiérarchique de base
$N_i \sim \text{Poisson}(\lambda), \quad n_{it} \mid N_i \sim \text{Binomial}(N_i, p)$
Version de base : pas de covariables, p fixé ou intercept

Limites des modèles

Carroll & Lombard (1985) : Problème : nombreuses observations nulles ($n_{it} = 0$) $\rightarrow$ excès de zéros Solution : estimation *poolée* par sommation des répétitions :

$$n_{.t} = \sum_{i=1}^{R} n_{it}$$

Limitation : perte d'information spatiale

Royle (2004) – modèle hiérarchique de base : Limitation principale : pas de covariables incluses pour p

Modèle de Royle avec covariables

Dans les extensions modernes, on peut inclure des covariables à la fois pour l'abondance et la détection :

$$\log(\lambda_i) = \beta_0 + \sum_j \beta_j x_{ij}, \quad \text{logit}(p_{it}) = \alpha_0 + \sum_j \alpha_j c_{it}^j$$

Exemple de covariables : turbidité, climat, pressions humaines, observateur

Avantage : estimation simultanée de l'abondance et de la probabilité de détection

Schéma d'un modèle d'abondance

Modèle hiérarchique

1

$$n_{it} \mid N_i \sim B(N_i, p_{it})$$

Dépend de covariable

$$\text{logit}(p_{it}) = \alpha_0 + \sum_j \alpha_j c_{it}^j$$

$$\log\left(\frac{p_{it}}{1 - p_{it}}\right) = \delta_{it}$$

$$p_{it} = \frac{1}{1 + e^{-\delta_{it}}}$$

2

$$N_i \sim \mathcal{P}(\lambda_i)$$

Dépend de covariables environnementales

$$\log(\lambda_i) = \beta_0 + \sum_j \beta_j x_{ij}$$

$$\lambda_i = \exp(X\beta)$$

N_i : ***Le nombre réel d'individus dans le site i***

p_{it} : ***La probabilité de détéction***

1

Extensions du modèle de Royle

Zéro-inflated Poisson (ZIP) et Négatif Binomial (ZINB) (Joseph et al., 2009)

- Permettent de gérer l'excès de zéros dans les données
- Intègrent l'occupation et certaines hétérogénéités
- Possibilité d'inclure des covariables pour λ_i et p_{it}

Modèle dynamique (Dail & Madsen, 2011)

- Permet de modéliser l'évolution temporelle de l'abondance

ZIP et ZINB

Ils introduisent un processus d'occupation pour expliquer les nombreux zéros via une variable latente z_i :

$$z_i \sim \mathcal{B}(\psi), \quad z_i = \begin{array}{ll} 1, & \text{site occupé} \\ 0, & \text{site non occupé} \end{array}$$

ZIP :

$$N_i \mid z_i \sim \mathcal{P}(\lambda_i z_i), \quad \begin{array}{ll} z_i = 1 & \Rightarrow N_i \sim \mathcal{P}(\lambda_i) \\ z_i = 0 & \Rightarrow N_i = 0 \end{array}$$

ZINB :

$$N_i \mid z_i \sim \mathcal{NB}(\mu_i z_i, r), \quad \begin{array}{ll} z_i = 1 & \Rightarrow N_i \sim \mathcal{NB}(\mu_i, r) \\ z_i = 0 & \Rightarrow N_i = 0 \end{array}$$

Modèle N-mixture généralisé (1/2)

Observation conditionnelle :

$$n_{i,t} \mid N_{i,t} \sim \text{Binomial}(N_{i,t}, p_{i,t})$$

Abondance réelle $N_{i,t}$ peut changer entre $t-1$ et t (population ouverte)

La dynamique de population est décrite par la loi jointe des abondances :

$$f(N_{i1}, \ldots, N_{iT}, \theta) = f(N_{i1}, \theta) \prod_{t=2}^{T} f(N_{i,t} \mid N_{i,t-1}, \theta)$$

La formule repose sur propriété de Markov d'ordre 1 :

$$f(N_{i,t} \mid N_{i,1}, \ldots, N_{i,t-1}) = f(N_{i,t} \mid N_{i,t-1})$$

Modèle N-mixture généralisé (2/2)

L'abondance est décomposée en deux processus :

$$N_{i,t} = S_{i,t} + G_{i,t}$$

Survie	Recrutement
$S_{i,t} \mid N_{i,t-1} \sim \text{Binomial}(N_{i,t-1}, \omega)$	$G_{i,t} \mid N_{i,t-1} \sim \text{Poisson}(\gamma(N_{i,t-1}))$

$S_{i,t}$: nombre d'individus survivants

$G_{i,t}$: nombre de nouveaux individus (naissance ou immigration)

ω : probabilité de survie locale

γ : fonction dépendant de la population précédente

Probabilité de transition (1/2)

On souhaite connaître :

$$P_{j,k} = \mathbb{P}(N_t = k \mid N_{t-1} = j), \quad \text{avec} \quad N_t = S_t + G_t$$

Chaque individu survit avec probabilité ω :

$$S_t \mid N_{t-1} = j \sim \mathcal{B}(j, \omega)$$

On peut avoir $c = 0, 1, \ldots, j$ survivants.

Les nouveaux individus suivent :

$$G_t \sim \mathcal{P}(\gamma(j))$$

On peut avoir $0, 1, 2, 3, \ldots$ recrues.

Probabilité de transition(2/2)

Pour obtenir $N_t = k$, on doit avoir :

$$S_t + G_t = k$$

Comme les événements sont indépendants :

$$P_{j,k} = \sum_{c=0}^{\min(j,k)} \mathbb{P}(S_t = c \mid N_{t-1} = j)\mathbb{P}(G_t = k - c \mid N_{t-1} = j)$$

Analyses descriptives élémentaires

On constate que les valeurs 1, 2, 3, 4 et 9 apparaissent souvent, en revanche la valeur 5 est moins fréquente.

La médiane se situe autour de 3, le nombre moyen d'individus récoltés

Une valeurs atypiques est présent, mais reste plausibles

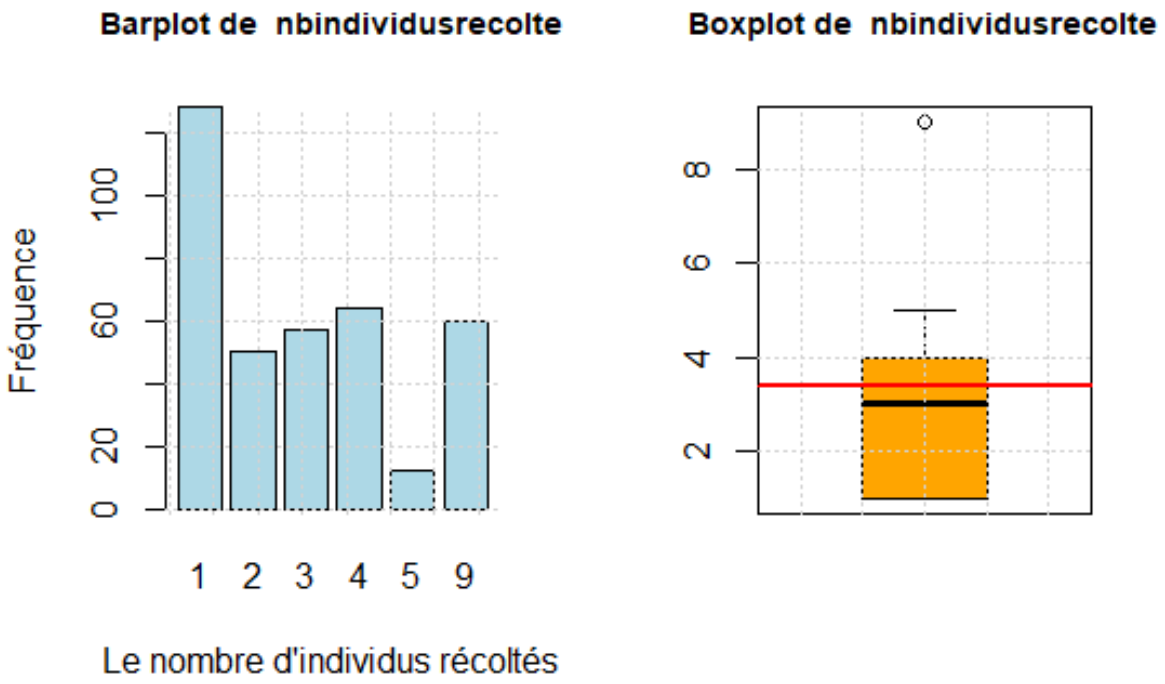

Figure 1: Distribution et boxplot du nombre d'individus récoltés

Analyses Multidimensionnelles

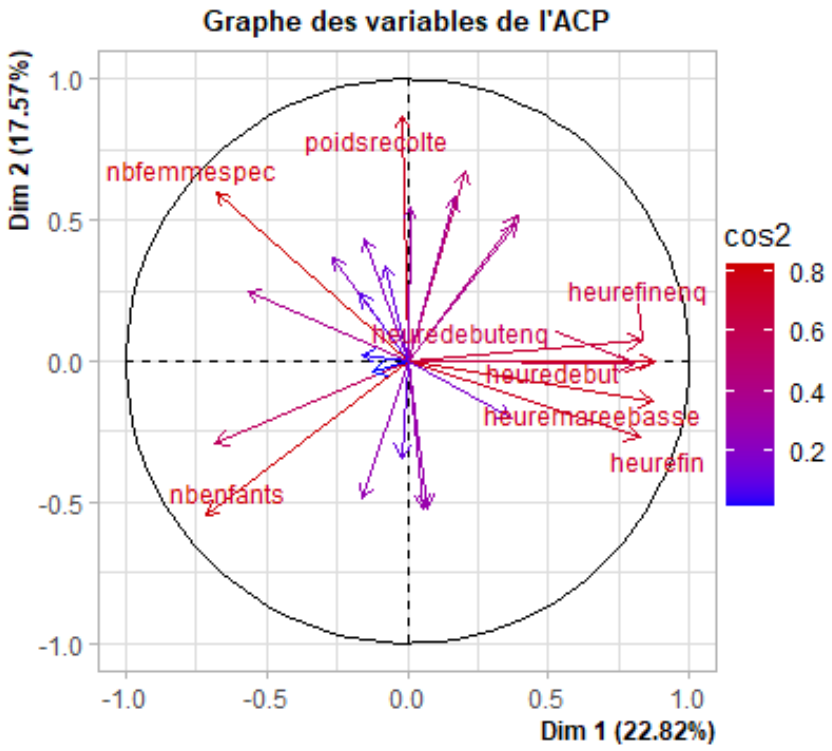

Figure 2: Variables dans le plan (1,2)

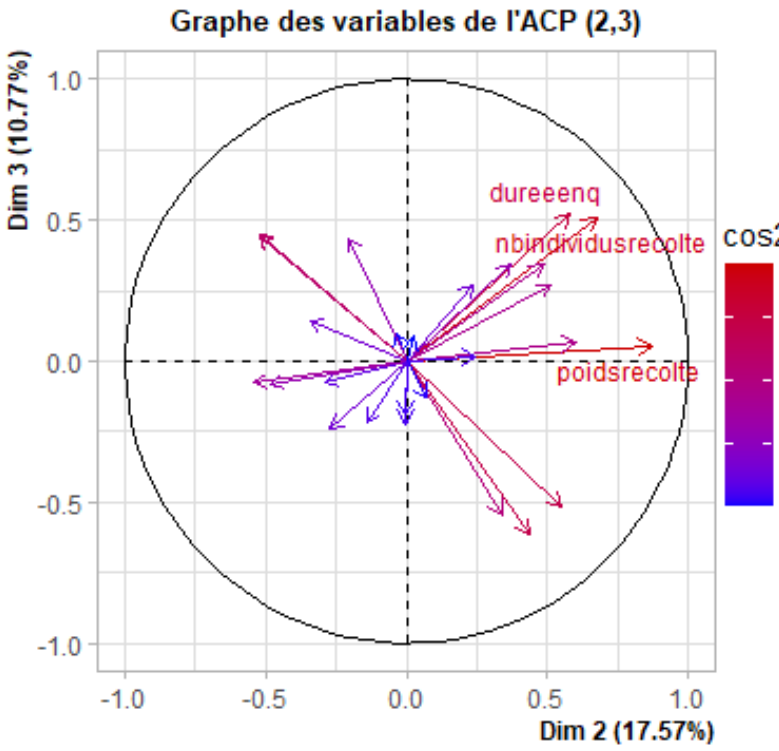

Figure 3: Variables dans le plan (1,3)

Conclusion

La revue bibliographique permet de définir un cadre solide

L'exploration des données montre des variables pertinentes et des patterns intéressants

Merci !

Pour votre attention et votre intérêt

ATTOUMANI Ibrahim